Napredni algoritmi i strukture podataka

Streaming podataka, Count-min sketch, HyperLogLog

Univerzitet u Novom Sadu
Fakultet Tehničkih Nauka

Streaming podatak

- Izraz *streaming* koristi se za opisivanje neprekidnih tokova podataka koji se kontinuirano generiše $[A, B, C, ..., \infty]$
- Ovaj pojam donosi konstantan niz podataka koji se mogu koristiti bez prethodnog skladištenja
- Ove podatke možemo da transformišemo, da ih skladištimo ili reagujemo kako dolaze
- Ovakve skupove podataka generišu razne vrste izvora, u različitim formatima i obimu

Count–min sketch - problem 1

Zaposlili ste se u Twitteru (jeee), vaš prvi zadatak je da napravite sistem za evidenciju hash tagova u objavama, da bi sledeći tim mogao da implementira bolji *trending* feature. Od vas se očekuje da napravite evidenciju frekfencije *hash tagova*, i pred vas su stavljena sledeća ograničenja i zahtevi:

- Sistem mora da radi sa *streaming* podacima
- Sistem mora da koristi malo resursa
- Sistem treba da omogući laku paralelizaciju
- 100 % preciznost nije obavezna

Predlozi :) ?

Count–min sketch - problem 2

Zaposlili ste se u Youtube-u (opaaa), vaš prvi zadatak je da napravite sistem za evidenciju pregleda video-a, da bi sledeći tim mogao da implementira bolji *recommender* sistem. Od vas se očekuje da napravite evidenciju frekfencije pregleda videa, i pred vas sustavljena sledeća ograničenja i zahevi:

- Sistem mora da radi sa *streaming* podacima
- Sistem treba da koristi malo resursa
- Sistem treba da omogući laku paralelizaciju
- 100 % preciznost nije obavezna

Predlozi :) ?

Count-min sketch - Uvod

- *Count-min sketch* je probabilistčka strukture podataka koja služi kao **tabela učestalosti dogadjaja** u *stream-u* podataka
- Ova strutura koristi *hash funkcije* za preslikavanje dogadjaja na frekvencije
- Za razliku od hash tabele koristi manje prostora, na račun precenjivanja nekih dogadjaja nastalih zbog kolizija hash funkcija
- Jednom kreirana, struktura ne raste, ma šta radili sa njom

- Ova struktura koristi **k** hash funkcija, slično kao i Bloom Filter
- Count-min sketch predstavlja tabelu gde registrujemo učestalost dogadjaja
- Svaka hash funkcija (k_i) se koristi **za korespodentni red** u tabeli
- Tabela ima **m** kolona, vrednost **nećemo birati nasumično**
- Preciznost ove strukture zavisi od toga koliko redova dodajemo, tj. koliko **hash funkcija koristimo**

- Inicijalno svaka ćelija unutar Count-min sketch (CMS) tabele se postavlja na vrednost **0**
- Ako imamo CMS sa **k** redova i **m** kolona onda je proces inicijaliacije sledeći:
  - $\forall i \in \{0, 1, ..., k\}$
  - $\forall j \in \{0, 1, ..., m\}$
  - $CMS[i, j] = 0$

Count-min sketch - Dodavanje

Ako dobijemo element iz stream-a sa ključem **K**, postupak dodavanja je sledeći:

- Propustimo element **K** kroz **svaku hash funkciju**: $\forall\ h_i \in \{1, ..., k\}$
- Dobijemo vrednost kolone: $j = h_i(K)\ \%\ m$
- Na preseku reda i kolone povećamo vrednost za **1**: $CMS[i, j] += 1$

Count-min sketch - Dobijanje vrednosti

Ako želimo da vidimo učestalost elementa **K**, postupak je sledeći:

- Propustimo element **K** kroz **svaku hash funkciju**: $\forall\ h_i \in \{1, ..., k\}$
- Dobijemo vrednost kolone: $j = h_i(K)\ \%\ m$
- Formiramo niz vrednosti sa odgovarajućih pozicija $R[i] = CMS[i, j], i \in \{0, ..., k\}$
- Uzmemo minimum iz niza i to je procena učestalosti dogadjaja **K**
  $E(K) = min(R[i]), i \in \{1, ..., k\}$

Count-min sketch - Primer

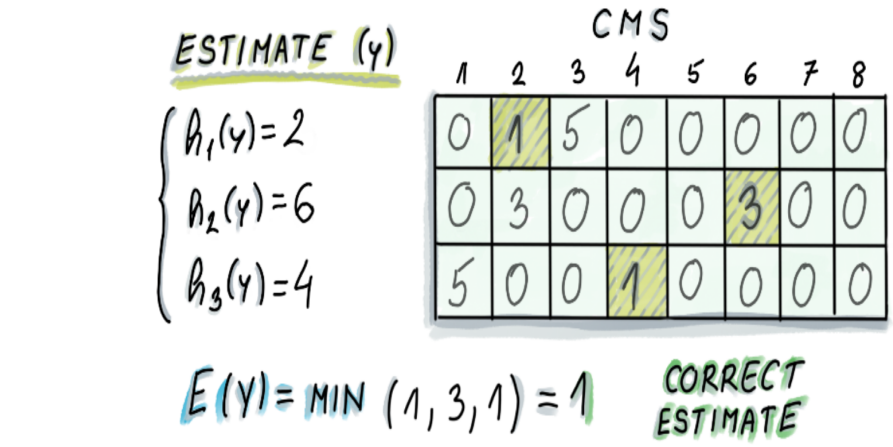

(Algorithms and Data Structures for Massive Datasets, Medjedovic, D. and Tahirovic, E. and Dedovic, I. ISBN: 9781638356561, Manning)

Count-min sketch - Izbor parametara

- Parametre **k** i **m** nećemo nasumično birati
- Kao i kod Bloom Filtera možemo da se oslonimo na malo matematike
- Ako hoćemo da definišemo tabelu veličine $k \times m$ treba da izaberemo preciznost (ε) koju želimo da postignemo, kao i sigurnost sa kojom dolazimo do tačnosti (δ)
- Dobijamo $k = [\ln \frac{1}{\delta}]$ i $w = [\frac{\epsilon}{\varepsilon}]$, gde je ϵ Ojlerov broj

ε	1 - δ	w	d	wd
0.1	0.9	28	3	84
0.1	0.99	28	5	140
0.1	0.999	28	7	196
0.01	0.9	272	3	816
0.01	0.99	272	5	1360
0.01	0.999	272	7	1940
0.001	0.999	2719	7	19033

(Introduction to Probabilistic Data Structures, DZone)

Napomena: $d = k, w = m$

Count-min sketch - Pitanja?

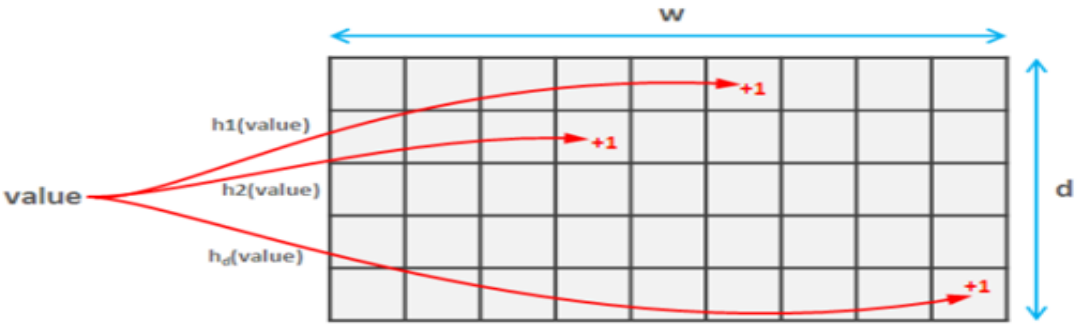

Pitanja :) ?

Count-min sketch - Dodatni materijali

- An improved data stream summary: the count-min sketch and its applications
- Algorithms and Data Structures for Massive Datasets
- Live example

HyperLogLog - Problem 1

Zaposlili ste se u Facebook-u (you rocks), i od vas se traži da izračunate broj različitih korisnika koji su posetili Facebook u datoj nedelji, gde se svaka osoba prijavljuje više puta dnevno. Ovo rezultuje velikim skupom podataka sa mnogo duplikata. Od vas se zahteva da:

- Ne potrosite previse resursa
- 100 % tačan podatak nije obavezan
- Lako paralelizujemo proces
- Sistem treba da radi i sa *streaming* podacima

Predlozi :) ?

HyperLogLog - Problem 2

Zaposlili ste se u Google-u (bravo majstori), i od vas se traži da izračunate broj različitih stvari koje su korisnici pretraživali svaki dan. Ovo rezultuje velikim skupom podataka sa mnogo duplikata. Od vas se zahteva da:

- Ne potrosite previse resursa
- 100 % tačan podatak nije obavezan
- Lako paralelizujemo proces
- Sistem treba da radi i sa *streaming* podacima

Predlozi :) ?

HyperLogLog - Uvod

- HyperLogLog (HLL) je probabilistička struktura podataka koja se koristi za izračunavanje kardinaliteta velikih skupova podataka
- Kao i Bloom Filter i Count-min sketch, i on se oslanja na *hash funkcije*
- Za razliku od prethodne dve strukture, on nema potrebu da skladišti hash-eve
- HLL u se memoriji reprezentuje kao fiksna strutura koja neće rasti sa dodavanjem elemenata
- HLL rešava problem pronalaženja kardinalnosti masovnog skupa podataka koji koristi manje od **1,5 KB** memorije i sa procenom greške manjom od **2 %**

- Sam algoritam je relativno jednostavan, ali matematika i dokazi u pozadini nisu baš :/
- Kao i prethodna dva algoritma, danas se prilično intenzivno koristi u raznim aplikacijama sa velikim skupovima podataka
- Pogotovo je koristan u Big Data, Streamin i Cloud aplikacijama gde su skopovi podataka veliki
- Zbog svoje osobine (kao i prethodne struture) mogu se čak koristiti i na sistemima sa ograničenim resursima

HyperLogLog - Ideja

- HLL prvo primenjuje hash funkciju na sve vrednosti i predstavlja ih kao **cele brojeve iste veličine**
- Zatim ih pretvara u **binarne vrednosti** i procenjuje kardinalnost iz **heširane vrednosti**, umesto iz samih zapisa
- Izlaz hash funkcije je podeljen na dva dela
  - *Bakete* na osnovu vodećih *(leading)* bitova
  - *Vredosti* najveći mogući broj krajnjih uzastopnih *(consecutive)* nula
- Ako dobijemo više uzastopnih nula iz krajnjeg desnog bita za isti baket, ažuriracćemo taj baket.

- Oslanjamo se na nekoliko parametara:
  - **p** koliko vodećih bitova koristimo za baket
  - **m** veliĭina seta
- Prvo moramo da odredimo koliko vodećih bitova korisitmo za baket **p** (kolika je preciznost)
- Vrednost **p** je obinočno u intervalu $[4, 16]$
- Veća vrednost **p** smanjuje grešku u brojanju, koristeći više memorije
- Nakon toga treba da izračunamo kolki nam set **m** trebam koristeći formulu $\mathrm{m} = 2^{\mathrm{p}}$

HyperLogLog - dodavanje

- Pretpostavimo da nakon hash funkcije i pretvaranja u binarni oblik, naš ključ **K** ima vrednost *1011011101101100000*
- Pretpostavimo da za preciznost odaberemo vrednost **4** ($p = 4$)
- Kao rezultat toga, znamo da je veličina seta $m = 2^4$ tj. **16** (po formuli $m = 2^p$)
- Iz dobijene binarne vrednosti *1011011101101100000* zaključujemo da je vrednost bucket-a gde ćemo upisati vrednost *1011* tj. **11**
- Vrednost koju upisujemo u baket *11* je *5*, zato što je broj nula sa kraja **5**, od ostalog dela binarnog zapisa *011101101100000*

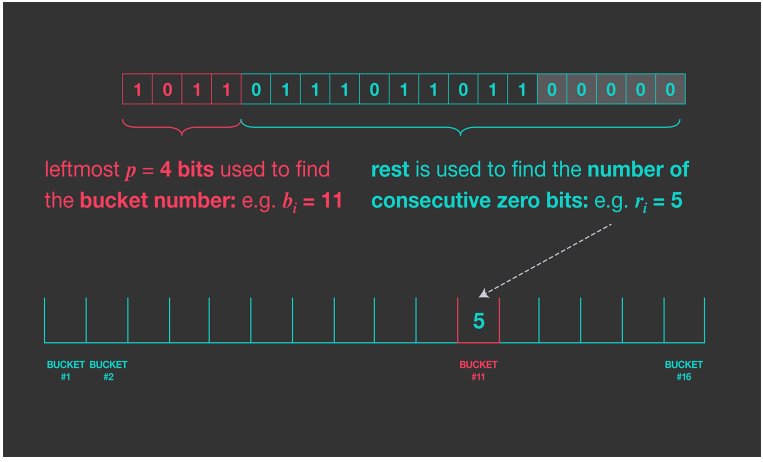

(HyperLogLog in Presto: A significantly faster way to handle cardinality estimation, Facebook engineering)

HyperLogLog - kardinalitet

- Durand-Flajolet je izveo konstantu da ispravi pristrasnost ka većim procenama (algoritam se zove LogLog).
- $constant = 0.79402$
- $\text{CARDINALITY}_{\text{HLL}} = constant * m * \frac{m}{\sum_{n=1}^{m} 2^{-R_j}}$
- R_j označavaju broj nula od krajnjeg levog bita
- Izraz $\sum_{j=1}^{m} 2^{-R_j}$ se naziva *harmonijska sredina* čime se postiže smanjenje greške bez poveć anja potrebne memorije (Za dokaz konsultovati originalan rad)

HyperLogLog - Pitanja

Pitanja :) ?

HyperLogLog - Dodatni materijali

- HyperLogLog Paper
- HyperLogLog playground
- Facebook engineering HyperLogLog
- Algorithms and Data Structures for Massive Datasets

Važna napomena

Formule za Bloom filter, Count-min sketch HyperLogLog ne trebate da učite napamet!!!
Nemojte to sebi raditi!