Organizacija datoteka



Serijska i sekvencijalna organizacija datoteke

Struktura, formiranje, traženje, obrada, ažuriranje, primena i ocena

Sadržaj

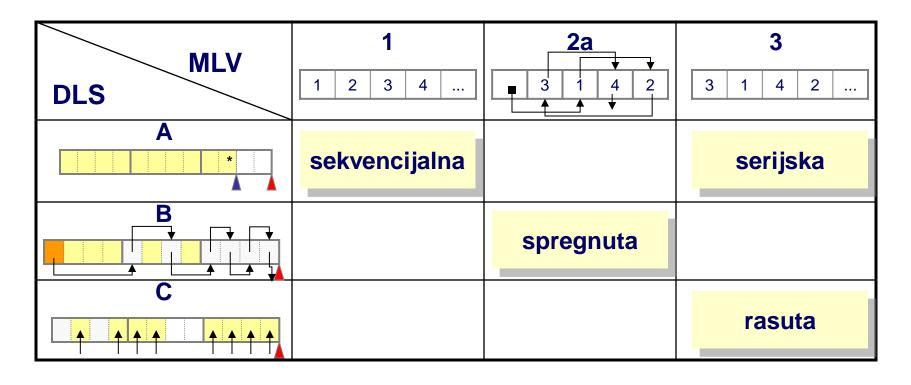


- Serijska organizacija datoteke
- Sekvencijalna organizacija datoteke



Vrste organizacije datoteka

Osnovne organizacije datoteka





Osnovna struktura

- slogovi smešteni jedan za drugim
 - u sukcesivne memorijske lokacije
- fizička struktura ne sadrži informacije o vezama između slogova logičke strukture datoteke
- ne postoji veza između vrednosti ključa sloga i adrese lokacije u koju je smešten
- redosled memorisanja slogova najčešće prema hronološkom redosledu njihovog nastanka
- slogovi mogu, a i ne moraju, biti blokirani



- Primer mala serijska datoteka D_{ser}
 - slogova N = 13
 - faktor blokiranja f = 3
 - slogovi
 - dvojke $(k(S_i), p(S_i))$
 - k(S_i) vrednost ključa
 - $p(S_i)$ konkretizacija ostalih obeležja sloga S_i (i = 1,...,13)
 - fizički blokovi
 - adrese (relativne) $A_i = i$: A_1 , A_2 , A_3 , A_4 i A_5
 - oznaka kraja datoteke: *

A ₁						
	34	p(S ₁)	07	$p(S_2)$	03	p(S ₃)

A ₂						
	15	p(S ₄)	19	p(S ₅)	29	p(S ₆)

A ₃						
	64	p(S ₇)	43	p(S ₈)	23	p(S ₉)

A ₄						
	27	p(S ₁₀)	13	p(S ₁₁)	49	p(S ₁₂)

A ₅					
	25	p(S ₁₃)	*		

it

Serijska organizacija datoteke

Formiranje serijske datoteke

- serijska datoteka se generiše
 - najčešće u postupku obuhvata podataka
- slogovi
 - formiraju se prenosom podataka sa različitih izvora
 - izvorna dokumenta
 - uređaji i softveri za očitavanje vrednosti (u realnom vremenu)
 - upisuju se jedan za drugim u sukcesivne memorijske lokacije
 - svaki novi slog se upisuje na kraj datoteke
- rezultat obuhvata podataka
 - neblokirana ili
 - blokirana serijska datoteka



Formiranje serijske datoteke

- obuhvat podataka
 - proces sa zadatkom da obezbedi inicijalno memorisanje ispravnih podataka
- osnovna aktivnost: upis podataka na medijum, izvršava je
 - čovek-operater, koristeći
 - program sa odgovarajućim UI-jem za formatiranje podataka i
 - odgovarajuće U/I uređaje, ili
 - specijalizovani softver sa odgovarajućim hardverskim uređajima



Formiranje serijske datoteke

- UI programa za obuhvat podataka format program
 - opis formata dokumenta raspored polja (layout), ekranska forma
 - pravila navigacije pomeranja kursora između polja
 - opisi i formatiranje sadržaja polja
 - specijalne kontrole sadržaja polja
 - dozvoljene operacije nad sadržajima polja



- Ul programa za obuhvat podataka
 - opis formata dokumenta raspored polja (layout)

	KADROVSKA EVIDENCIJA podaci o radnicima	
Oznaka datoteke		Redni broj sloga
Preduzeće	Radna jedinica	
Matični broj ra	adnika	
Prezime	Ime	Datum rođenja
Opština	Adresa	
Radno mesto	Broj bodova	
Pozicija kursora	Pritisni ENTER za upis Tip polja	



- Ul programa za obuhvat podataka
 - pravila navigacije pomeranja kursora između polja
 - mogućnost pristupa poljima putem miša ili tastature
 - redosled obilaska polja u navigaciji
 - putem tipke <TAB>, <ENTER>, ili automatskoj



- Ul programa za obuhvat podataka
 - opisi i formatiranje sadržaja polja
 - fiksni tekst (naslov) i tekstuelno uputstvo sa opisom polja
 - tip polja (alfa, numeričko, alfanumeričko, datumsko)
 - način vizuelizacije sadržaja
 - tekstuelno polje, padajuća lista, combo-box, radio-grupa
 - polje skrivenog sadržaja
 - format maska za numeričke ili datumske vrednosti
 - zadavanje vizuelnih atributa polja na formi
 - maksimalni broj znakova koji je moguće uneti
 - način poravnavanja sadržaja polja (levo, desno, centrirano)
 - način preloma sadržaja tekstuelnih polja (bez preloma, prelom na jedan znak, prelom na celu reč)



- Ul programa za obuhvat podataka
 - specijalne kontrole sadržaja polja
 - obaveznost unošenja barem jednog znaka u polje
 - obaveznost kompletnog popunjavanja sadržaja polja
 - kontrola na dozvoljeni opseg (domen) vrednosti
 - kontrola po modulu samo za numerička polja
 - broju od n cifara pridružuje se jedna kontrolna cifra koja se izračunava primenom posebnog algoritma na broj od n cifara
 - provera da li se uneti podatak nalazi u tabeli / listi dozvoljenih vrednosti



- UI programa za obuhvat podataka
 - dozvoljene operacije nad sadržajima polja
 - ručni unos sadržaja polja
 - modifikacija postojećeg sadržaja polja
 - brisanje sadržaja jednog, izabranih, ili svih polja
 - dupliciranje sadržaja jednog, izabranih, ili svih polja
 - u cilju povećava produktivnost operatera
 - kada se isti ili skoro isti sadržaj polja više puta ponavlja



Formiranje serijske datoteke

- obuhvat podataka vreme obavljanja
 - u realnom vremenu
 - na mestu i u trenutku nastanka podataka
 - u odloženom režimu (naknadno)
 - nakon određenog intervala vremena od nastanka podataka
 - po pravilu ga realizuje operater koji nije evidentirao izvorne podatke, na osnovu manuelno izrađenih dokumenata
 - verifikacija

verifikacija

- postupak suštinske provere ispravnosti unetih podataka (ručni, ili automatizovan)
 - npr. drugi operater ponovo unosi jednom već unete podatke koristeći isti izvorni dokument
 - npr. korišćenje inteligentnih softverskih rešenja



Traženje sloga u serijskoj datoteci

- traženje slučajno odabranog sloga
 - ne postoji funkcionalna veza između vrednosti ključa i adrese lokacije sloga
 - traženje logički narednog = traženje slučajno odabranog
- primena metode linearnog traženja
 - počinje od početka datoteke
 - pristupanje sukcesivno memorisanim blokovima i slogovima
- uspešno traženje, ukupan broj pristupa R_u :

$$1 \le R_u \le B$$

– neuspešno traženje, ukupan broj pristupa R_n :

$$R_n = B$$

B – ukupan broj blokova serijske datoteke



Traženje sloga u serijskoj datoteci

- - f faktor blokiranja
 - + 1 zbog specijalnog sloga sa oznakom kraja datoteke
- uspešno traženje, očekivani (srednji) broj pristupa
 - verovatnoća traženja bilo kog sloga datoteke je ista, 1 / N

$$\overline{R}_{u} = \frac{B}{N} \left(N - \frac{f(B-1)}{2} \right)$$

• kada $f \mid N$, tj. B = N / f + 1, ili kada je N >> 1, tada:

$$\overline{R}_u = \frac{B}{2}$$



Traženje sloga u serijskoj datoteci

– uspešno traženje, ukupan broj upoređivanja argumenta traženja i vrednosti ključa U_u :

$$1 \leq U_u \leq N$$

- uspešno traženje, očekivani (srednji) broj upoređivanja argumenta traženja i vrednosti ključa
 - verovatnoća traženja bilo kog sloga datoteke je ista, 1 / N

$$\overline{U}_u = \frac{N+1}{2}$$

– neuspešno traženje, ukupan broj upoređivanja argumenta traženja i vrednosti ključa U_n :

$$U_n = N$$



Obrada serijske datoteke

- vrste
 - direktna obrada
 - redosledna obrada
 - ukoliko se ide na sekvencijalni pristup slogovima u hronološkom redosledu
- može se koristiti kao vodeća u režimu direktne obrade
- može se koristiti kao vodeća u redoslednoj obradi datoteke čiji ključ sadrži
 - kao svoj strani ključ
 - kada je uređena saglasno neopadajućim vrednostima tog stranog ključa



Obrada serijske datoteke

- program koji vrši redoslednu obradu serijske datoteke
 - učitava sukcesivne slogove vodeće datoteke
 - svaki naredni slog vodeće datoteke sadrži logički narednu vrednost ključa obrađivane serijske datoteke
 - te vrednosti ključa se koriste kao argumenti za traženje u serijskoj datoteci metodom linearnog traženja
- u režimu direktne obrade
 - sukcesivni slogovi vodeće datoteke sadrže slučajno odabrane vrednosti ključa obrađivane serijske datoteke
 - traženje je, ponovo, linearno
- traženje logički narednog i slučajno odabranog sloga serijske datoteke
 - obavlja se identično, krećući od prvog sloga datoteke



Obrada serijske datoteke

- putem vodeće datoteke od $N_v = N_v^u + N_v^n$ slogova
 - N_v^u slogova inicira uspešna traženja
 - N_vⁿ slogova inicira neuspešna traženja
- inicira ukupan prosečni broj traženja

$$\overline{R}_{uk} = N_v^u \overline{R}_u + N_v^n \overline{R}_n$$

$$\overline{R}_{uk} \approx N_v^u \frac{B}{2} + N_v^n B$$

 broj pristupa se ne razlikuje za slučaj direktne i redosledne obrade

 A_3



- Primer mala serijska datoteka D_{ser}
 - slogova N = 13
 - faktor blokiranja f = 3



- Sadržaj vodeće datoteke:
- 64, 21, 8, 3
- Redosledna obrada
 - Sadržaj vodeće datoteke:
 - 3, 8, 21, 64

A ₁						
	34	p(S ₁)	07	$p(S_2)$	03	p(S ₃)

4 ₂						
	15	p(S ₄)	19	p(S ₅)	29	p(S ₆)

64	p(S ₇)	43	p(S ₈)	23	p(S ₉)

27	p(S ₁₀)	13	p(S ₁₁)	49	p(S ₁₂)

A_5					
	25	p(S ₁₃)	*		



Ažuriranje serijske datoteke

- upis novog sloga
 - u prvu slobodnu lokaciju na kraju datoteke
 - mora mu prethoditi jedno neuspešno traženje
 - jednostavan, ali zahteva veliki broj pristupa

$$R_{i} = \begin{cases} R_{n} + 1, & \neg (f \mid (N+1)) \\ R_{n} + 2, & f \mid (N+1) \end{cases}$$

svaki f-ti put neophodno je proširiti datoteku novim blokom



Ažuriranje serijske datoteke

- brisanje postojećeg sloga
 - mora mu prethoditi jedno uspešno traženje
 - najčešće samo logičko izmenom statusa aktuelnosti sloga
 - fizičko brisanje bi zahtevalo veliki broj pristupa
- modifikacija sadržaja postojećeg sloga
 - mora mu prethoditi jedno uspešno traženje
- očekivani broj pristupa za
 - logičko brisanje ili
 - modifikaciju sadržaja sloga

$$\overline{R}_d = \overline{R}_u + 1$$



Oblasti primene i ocena karakteristika

- pogodne kao male datoteke
 - kada mogu stati cele u OM
 - zbog veoma velikog broja pristupa potrebnog za pronalaženje logički narednog ili slučajno odabranog sloga
 - druge vrste organizacije donose samo mala poboljšanja u efikasnosti obrade malih datoteka
- serijska organizacija podataka u kombinaciji sa indeksnim strukturama
 - veoma pogodna za direktnu obradu
 - osnovna fizička struktura relacionih baza podataka
- serijska datoteka kao rezultat obuhvata podataka
 - polazna osnova za izgradnju datoteka sa drugim vrstama organizacije podataka

Sadržaj

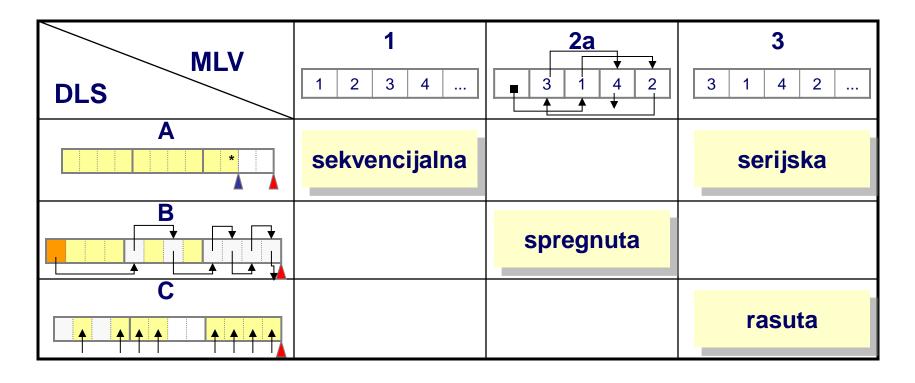


- Serijska organizacija datoteke
- Sekvencijalna organizacija datoteke



Vrste organizacije datoteka

Osnovne organizacije datoteka





Osnovna struktura

- slogovi su smešteni sukcesivno jedan za drugim
- logički susedni slogovi smeštaju se u fizički susedne lokacije
 - postoji informacija o vezama između slogova logičke strukture podataka datoteke, ugrađena u fizičku strukturu
 - realizovana kao linearna logička struktura podataka
 - smeštanjem sloga sa većom vrednošću ključa u lokaciju sa većom adresom
 - rastuće uređenje po vrednostima ključa ⇒ slog sa najmanjom vrednošću ključa smešta se u prvu lokaciju
- naziva se i fizički sekvencijalnom organizacijom



Osnovna struktura

- veza između memorisanih vrednosti ključa k(S) i adresa lokacija
 - nije ugrađena u strukturu datoteke
 - ne predstavlja bilo kakvu matematičku funkciju
- slogovi se smeštaju u blokovima od po f (≥1) slogova
 - poželjno da faktor blokiranja f bude što veći
- savremeni OS (*Unix*) i programski jezici (*C*, *C*++,
 Java) podržavaju samo sekvencijalni način pristupa
 - korisnicima je ostavljeno da naprave svoje sopstvene sekvencijalne metode pristupa

 A_{4}

- Primer mala sekvencijalna datoteka D_{sek}
 - slogova N = 13
 - faktor blokiranja f = 3
 - slogovi
 - isti sadržaj kao i D_{ser}
 - dvojke $(k(S_i), p(S_i))$
 - k(S_i) vrednost ključa
 - $p(S_i)$ konkretizacija ostalih obeležja sloga S_i (i = 1,...,13)
 - oznaka kraja datoteke: *
 - indeksi i (i=1,...,13)
 ukazuju na logički redosled smeštanja slogova

A ₁						
	03	p(S ₁)	07	p(S ₂)	13	p(S ₃)

A_2						
	15	p(S ₄)	19	p(S ₅)	23	p(S ₆)

A ₃						
	25	p(S ₇)	27	p(S ₈)	29	p(S ₉)

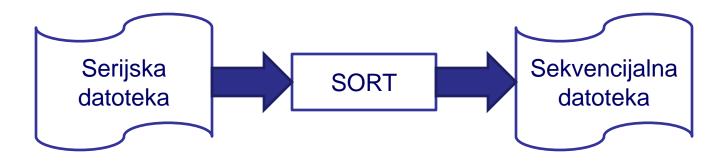
34	p	(S ₁₀)	43	p(S ₁₁)	49	p(S ₁₂)

64	p(S ₁₃)	*		



Formiranje sekvencijalne datoteke

- najčešće sortiranjem serijske datoteke
- saglasno rastućim ili opadajućim vrednostima ključa





Traženje sloga u sekvencijalnoj datoteci

- logički narednog ili
- slučajno odabranog

traženje slučajno odabranog sloga

- moguća primena metoda
 - linearnog traženja
 - binarnog traženja
- nema praktičnog smisla ako je datoteka velika i smeštena na eksterni memorijski uređaj
- ima praktičnog smisla ako je cela datoteka smeštena u OM
 - nju, u tom slučaju, može predstavljati
 - » neka linearna struktura nad skupom slogova ili
 - » blok neke druge datoteke, npr. indeks-sekvencijalne



Traženje sloga u sekvencijalnoj datoteci

- traženje logički narednog sloga
 - linearnom metodom traženja
 - počevši od prvog, fizički susedni blokovi se učitavaju u OM
 - u centralnoj jedinici se vrši upoređivanje argumenata traženja i vrednosti ključa sukcesivnih slogova dok se
 - traženi slog ne pronađe
 - argument traženja ne postane manji od vrednosti ključa sloga
 - ne dođe do kraja datoteke
 - traženje novog, logički narednog sloga, započinje od sloga na kojem se prethodno traženje zaustavilo
 - tekućeg sloga datoteke



- Traženje sloga u sekvencijalnoj datoteci
 - traženje logički narednog sloga
 - broj pristupa pri uspešnom i pri neuspešnom traženju

$$0 \le R \le B - i$$

- *i* redni broj tekućeg bloka u odnosu na početak
- broj poređenja argumenata traženja i vrednosti ključeva slogova, pri uspešnom i neuspešnom traženju

$$1 \leq U \leq N - i + 1$$

i - redni broj tekućeg sloga



Obrada sekvencijalne datoteke

- redosledna
- direktna

direktna obrada

- ima smisla ako je sekvencijalna datoteka mala, tako da se može smestiti u operativnu memoriju
- performanse obrade malo se razlikuju od performansi obrade serijske datoteke

$$\overline{R}_{uk} = N_v^u \overline{R}_u + N_v^n \overline{R}_n$$

$$\overline{R}_{uk} \approx N_v^u \frac{B}{2} + N_v^n \frac{B}{2}$$



Obrada sekvencijalne datoteke

- vodeća datoteka u direktnoj i redoslednoj obradi
 - česta upotreba
 - sukcesivno učitavanje fizički susednih slogova, počevši od prvog pa do poslednjeg
 - ukupan broj pristupa, kada se sekvencijalna datoteka koristi kao vodeća u obradi

$$R_{uk} = B = \left\lceil \frac{N+1}{f} \right\rceil$$



Obrada sekvencijalne datoteke

- redosledna obrada
 - iterativan proces
 - vodeća datoteka generiše logički naredne vrednosti ključa za traženje u obrađivanoj, sekvencijalnoj datoteci
- svaki korak obrade = traženje logički narednog sloga
 - vrši se metodom linearnog traženja
- svaki blok datoteke učitava se u OM samo jedanput
- vodeća datoteka sadrži N_v (N_v≥ 1) slogova
 - uključuje vrednost ključa veću ili jednaku najvećoj vrednosti ključa u obrađivanoj datoteci



Obrada sekvencijalne datoteke

- redosledna obrada
- ukupan broj pristupa

$$R_{uk} = B$$

srednji broj pristupa po jednom traženju

$$\overline{R} = \frac{B}{N_v}$$

- što je R manji, obrada je efikasnija
- poželjniji veći faktor blokiranja f i veći broj traženja N_{ν}
- ukupan broj upoređivanja $U \ge N + N_v$
- srednji broj upoređivanja $\overline{U} \ge \frac{N}{N_v} + 1$



- upis novog sloga
 - pronalaženje mesta upisa novog sloga neuspešno traženje
 - lokacija sloga sa prvom većom vrednošću ključa od datog
 - pomeranje za jednu lokaciju udesno svih slogova sa vrednostima ključa većim od vrednosti ključa novog sloga
- brisanje postojećeg sloga
 - prethodno pronalaženje sloga uspešno traženje
 - pomeranje za jednu lokaciju ulevo svih slogova sa većom vrednošću ključa, ako se brisanje vrši fizički
- modifikacija sadržaja sloga
 - prethodno pronalaženje sloga uspešno traženje
- upis i brisanje: ozbiljan problem ukupnog broja pristupa



Ažuriranje sekvencijalne datoteke

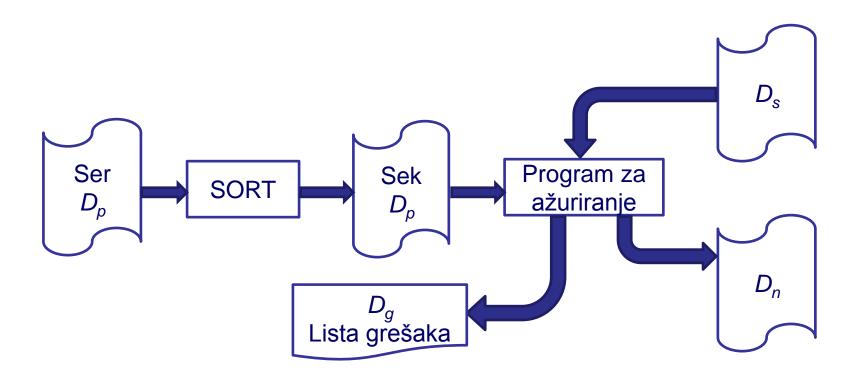
- u režimu direktne obrade
 - u proseku, pomeranje polovine od ukupnog broja slogova za jednu lokaciju udesno (pri upisu) ili ulevo (pri brisanju) sloga
 - primenjuje se kada je kompletna datoteka smeštena u OM

u režimu redosledne obrade

- poseban iterativni postupak
 - kreiranje potpuno nove datoteke, na osnovu postojeće
- primeren kada se datoteka ne može kompletno smestiti u operativnu memoriju
- datoteke i uloge u obradi
 - − D_s
 obrađivana, ulazna (stara) sekvencijalna datoteka
 - $-D_n$ obrađena, izlazna (nova) sekvencijalna datoteka
 - D_p
 vodeća datoteka promena, serijska, ulazna
 - D_a
 datoteka grešaka, izlazna



- Ažuriranje sekvencijalne datoteke
 - u režimu redosledne obrade



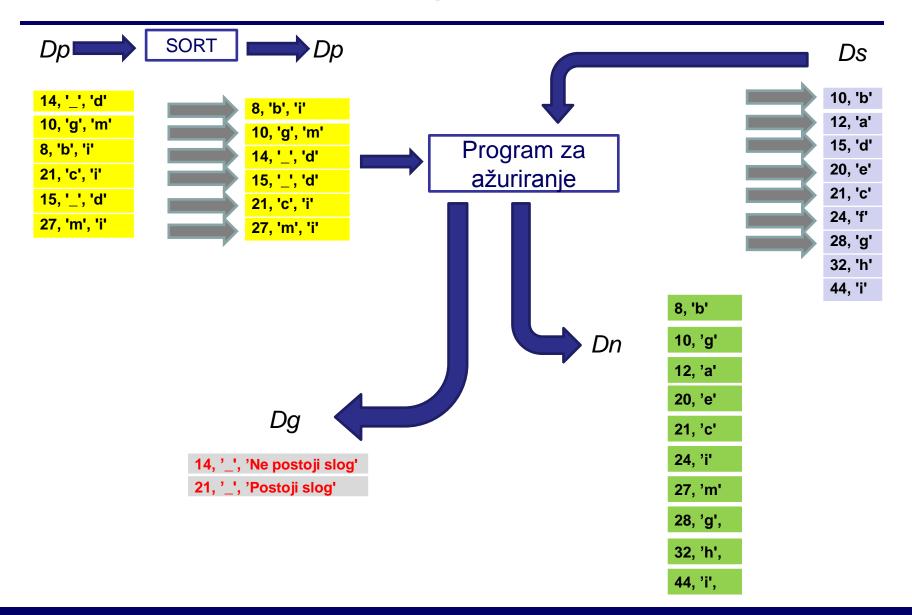


- u režimu redosledne obrade
- format sloga datoteke D_s i D_n identičan $(k(S_i), p(S_i))$
- format sloga datoteke promena D_p : $(k(S_i), p_p(S_i), s_p(S_i))$
 - $s_p(S_i)$ polje statusa izvršene operacije, moguće vrednosti:
 - -n novi slog, m podaci za modifikaciju, b slog za brisanje
- format sloga datoteke grešaka D_g : $(k(S_i), p(S_i), s_g(S_i))$
 - $s_q(S_i)$ polje opisa greške, moguće vrednosti ukazuju na:
 - pokušaj upisa već postojećeg sloga u datoteku
 - pokušaj brisanja ili modifikacije nepostojećeg sloga datoteke



- u režimu redosledne obrade
 - sekvencijalni pristup sa učitavanjem slogova $S_s(D_s)$ i $S_p(D_p)$
 - upoređivanje vrednosti ključeva tekućih slogova
 - generisanje novih slogova $S_n(D_n)$ na osnovu sadržaja tekućih slogova S_s i S_p
 - upis slogova S_n u datoteku D_n
- dužina intervala između dva ažuriranja
 - određuje se tako da se tokom njega nakupi toliki broj promena koji bi opravdao pristupanje svim slogovima stare i generisanje nove datoteke
 - duži interval ⇒ veća efikasnost obrade, ali i duže vreme neusaglašenosti sadržaja datoteke sa realnim stanjem







- u režimu redosledne obrade
- datoteka promena D_p sadrži $N_v = N_v^n + N_v^b + N_v^m$ slogova
 - $-N_v^n$ za upis, N_v^b za brisanje i N_v^m za modifikaciju

– i
$$B_v$$
 blokova:

$$B_{v} = \left\lceil \frac{N_{v} + 1}{f} \right\rceil$$

- postojeća datoteka D_s sadrži B_s blokova: $B_s = \left| \frac{N+1}{f} \right|$
- nova datoteka D_n sadrži B_n blokova:

$$B_n = \left\lceil \frac{N + N_v^n - N_v^b + 1}{f} \right\rceil$$



- u režimu redosledne obrade
- srednji broj pristupa pri ažuriranju datoteke za jedno traženje logički narednog sloga

$$\overline{R} = \frac{B_{v} + B_{s} + B_{n}}{N_{v}}$$



Oblasti primene i ocena karakteristika

- prednosti
 - najpogodnija fizička organizacija za redoslednu obradu
 - ekonomično korišćenje memorijskog prostora
 - mogućnost korišćenja i magnetne trake i magnetnog diska, kao medijuma

nedostaci

- nepogodnost za direktnu obradu
- potreba sortiranja pri formiranju
- relativno dugotrajan postupak ažuriranja



Oblasti primene i ocena karakteristika

- najpogodnija fizička organizacija za redoslednu obradu
 - režim redosledne obrade često se koristi u praksi, u paketnoj (batch) obradi podataka
 - posledica činjenice da su logički susedni slogovi smešteni u fizički susedne lokacije
 - učitavanjem jednog bloka u OM, pribavlja se f slogova koji najverovatnije učestvuju u narednim koracima obrade
 - poželjno je da f bude što veći
 - kada N_v → N, tada R → 1 / f, te se s povećanjem f poboljšava efikasnost obrade

Sadržaj



- Serijska organizacija datoteke
- Sekvencijalna organizacija datoteke



Pitanja i komentari







Serijska i sekvencijalna organizacija datoteke

Struktura, formiranje, traženje, obrada, ažuriranje, primena i ocena